


PROYECTO PREDICCIÓN DE IMPORTACIÓN DE ENERGÍA ELÉCTRICA

Ursula Macedo

Coderhouse- Data Science II comisión-
Comisión 94230



ÍNDICE


- ▶ Introducción - Caso de negocio
 - ▶ Descripción de los datos
 - ▶ Análisis EDA
 - ▶ Metodología
 - ▶ Conclusiones y resultados
- 
- A series of parallel teal lines of varying lengths and orientations, located in the bottom right corner of the slide, creating a modern, abstract graphic element.

INTRODUCCIÓN - CASO DE NEGOCIO

Analizar la oferta y demanda de energía eléctrica a lo largo del tiempo no solo permite detectar tendencias y estacionalidades, sino que también permite comprender como se despacha la energía en diferentes contextos.

Esta información resulta clave a la hora de tomar decisiones para gestionar la demanda y oferta de manera eficiente, prever picos de consumo y planificar en consecuencia reduciendo riesgos de desabastecimiento y optimizando los recursos disponibles.

Por ello, en base a la variabilidad y estacionalidad de la generación y la demanda de la población, la empresa busca predecir la importación de energía de países vecinos para gestionar las compras minimizando los costos y riesgos.



DESCRIPCIÓN DE LOS DATOS

Datos de oferta y demanda de energía eléctrica en Argentina desde el año 2022 a 2024 Fuente: CAMMESA (Compañía Administradora del Mercado Mayorista Eléctrico Sociedad Anónima) <https://cammesaweb.cammesa.com/>



- El df contiene columnas de tiempo:

Año, mes (formato mes-año), n° mes, n° día, Tipo de día(hábil, no hábil), día (dia de la semana), fecha (formato día/mes/año), hora

- Columnas de generación de energía eléctrica en MWh:

Nuclear ,Biogas , Biomasa, Eólica, Solar, Ciclos Combinados, Motor Diesel, Turbina a gas, Turbovapor, Importación, Hidráulica > 50 (datos de generación hidroeléctrica mayor a 50 MW), Hidráulica < 50 (datos de generación hidroeléctrica menor a 50 MW)

- Columnas con datos totales y de demanda eléctrica:


GENERACION TOTAL: Suma de MWh de fuentes de generación

Gran Usuario MEM: Demanda de grandes usuarios en MWh, la misma está compuesta por la demanda de la categoría GUMA (Gran Usuario Mayorista Autogenerador) como ejemplo se pueden mencionar las demandas de las empresas Arcor, Acindar, aysa, molinos cañuelas entre otras.)

DISTRIBUIDOR (demanda estacional+GUMEs): La categoría distribuidor comprende la demanda en MWh de la demanda estacional y las GUMEs (Grandes Usuarios Menores) como ejemplo se pueden mencionar cooperativas, Edelap, Edenor, Edesur, EPEC entre otros.

DEMANDA LOCAL [MWh]: La demanda local es la suma de las demandas Gran Usuario MEM y Distribuidor (demanda estacional+GUMEs)



ANÁLISIS EDA



Verificación de valores nulos por columnas

AÑO	0
TIPODIA	0
FECHA	0
HORA	0
NUCLEAR	0
BIOGAS	0
BIOMASA	0
EOLICA	0
HIDRO_MAS_50	0
HIDRO_MENOS_50	0
SOLAR	0
CC	0
MDIESEL	0
TG	0
TV	0
IMPORTACION	0
GENERACIONTOTAL	0
DEMANDALOCAL	0

Outliers columnas



Tipos de Fuentes

Gráfico 4: Suma de generación renovable






Gráfico 5: Suma de generación termica




Distribución Fuentes

Gráfico 8: Distribución columnas Generación





Frecuencia Fuentes

Gráfico 7: Frecuencias columnas Generación



Frecuencia y distribución Generación total vs Demanda total

Se verifica que la distribución de las variables generación y demanda total tienen asimetría positiva, teniendo algunos valores pico y la mayoría en valores mas bajos que los picos. También se observa que coinciden en su distribución.




Correlaciones entre variables

Se puede observar los valores en rojo con correlación positiva , es decir, si una variable aumenta la otra también aumenta.


Por ejemplo, generación y demanda total, año y fecha.

Para Ciclos combinados(CC) y Motor Diesel la correlación es positiva respecto a la demanda y generación, por lo cual se puede inferir que al aumentar la demanda aumenta la generación de esas fuentes.



Generación y demanda vs Importación 2022-2024


Gráfico 6: generación, demanda, importación vs fecha



Se puede visualizar la dependencia de importación generación y demanda respecto a la estacionalidad. A mayor demanda mayor importación

Generación y demanda vs Importación 2024


Gráfico 10: Generación, demanda vs importación para 2024



Generación total vs demanda total para 31/1/24


Se puede visualizar una curva típica horaria de verano con el pico de demanda y generación de 14 a 18 h. También se visualiza que para este día la curva de generación cubre la demanda total.

Gráfico 12: Generación total vs demanda total para 31/1/2024




Distribución de fuentes para 31/1/2024 vs demanda


Gráfico 16: Distribución de fuentes para 31/1/2024 vs demanda




METODOLOGÍA



Metodología



Se separaron los datos :
80% test y 20% train

- Se evaluó un primer modelo Random Forest Regressor con `n_estimators=100`, `max_depth=20`
 - Se evaluaron los modelos AdaBoost, LightGBM y XGBoost para encontrar el que mejor se ajuste al df.
 - Se compararon las métricas de todos los modelos y se aplicaron mejoras mediante tuning de hiperparámetros al modelo elegido.
- 

CONCLUSIONES Y RESULTADOS

Several parallel teal lines of varying lengths and slopes are positioned on the right side of the slide, extending from the top right towards the bottom right.

Métricas

Para evaluar la performance de diferentes modelos se pueden utilizar distintas métricas:

- y_i : valor real
- $\hat{y}_i$: valor estimado
- n : número total de observaciones

Mean Absolute Error (MAE): Promedio de la diferencia absoluta entre los valores reales y estimados.

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Root Mean Square Error (RMSE): Raíz cuadrada del promedio de la diferencia al cuadrado entre valores reales y estimados.

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

R^2 : Mide la proporción de varianza de la variable dependiente explicada por la variable (s) independiente(s).

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$



Métricas y resultados

Modelo	Conjunto	RMSE	MAE	R2
Random Forest regressor	Train	67.673	42.815	0.991
Random Forest regressor	Test	168.094	109.202	0.946
AdaBoost	Train	586.526.772	506.989.668	0.350732
AdaBoost	Test	591.182.680	509.870.178	0.330956
LightGBM	Train	135.134.251	95.394.581	0.965535
LightGBM	Test	160.955.768	112.848.072	0.950407
XGBoost	Train	93.049.923	67.490.228	0.983659
XGBoost	Test	158.442.590	112.996.709	0.951943
XGBoost Tuned	Train	57.893.992	41.761.157	0.993674
XGBoost Tuned	Test	124.798.837	87.654.122	0.970185

El mejor modelo es XGBRegressor con best_params para estimar la variable IMPORTACION

Muestra buen rendimiento para nuevos datos , métrica MAE alrededor del 87 MWh y r2 cercano a 0,97

Random Forest vs XGBoost tuned



El modelo mejorado
XGBoost Tuned, logra
reducir la métrica MAE
un 38% en Train y un
22% en test

MUCHAS GRACIAS

